

# Bootstrap

Clément Dell'Aiera, Guillaume Rateau

## **Résumé**

## Table des matières

<b>1</b>	<b>Bootstrap et valeurs extrêmes</b>	<b>3</b>
1.1	Théorèmes des valeurs extrêmes . . . . .	3
<b>2</b>	<b>Estimation de la vitesse de convergence par régression</b>	<b>4</b>

# 1 Bootstrap et valeurs extrêmes

## 1.1 Théorèmes des valeurs extrêmes

**Théorème 1.** Si , pour une fonction de répartition  $F$ , il existe des suites réelles  $a_n > 0$  et  $b_n$  telles que, en tout point de continuité de  $F$  :

$$\lim_{n \rightarrow \infty} F^n(a_n x + b_n) = G_\alpha(x),$$

la loi limite  $G$  est de la forme :

$$G_\alpha(x) = \exp(-(1 + \alpha x)^{-\frac{1}{\alpha}}) \quad \text{pour } 1 + \alpha x > 0$$

Le paramètre  $\alpha$  donne de l'information sur la queue de la distribution : c'est un paramètre d'intérêt servant à prédire les événements rares. Toutefois, les méthodes de Bootstrap naïves ne fonctionnent plus dans le cas des valeurs extrêmes, à cause d'un potentiel biais.

Remarque :  $G_0(x) = \exp\{e^{-x}\}$ .

1. Si  $\alpha > 0$ , on dit que  $F$  est dans le domaine d'attraction de la loi de Fréchet, domaine des lois à queues épaisses (décroissance en loi de puissance).
2. Si  $\alpha = 0$ , on dit que  $F$  est dans le domaine d'attraction de la loi de Gumbel (queues légères).
3. Si  $\alpha < 0$ , on dit que  $F$  est dans le domaine d'attraction de la loi de Weibull (queues finies).

Domaine	Gumbel	Fréchet	Weibull
<b>Lois</b>	Normale Exponentielle Fréchet Lognormale Gamma Weibull	Cauchy Pareto Student	Uniforme Beta

FIGURE 1 – Quelques exemples de lois appartenant à différents domaines.

## 2 Estimation de la vitesse de convergence par régression

Dans toute cette partie, l'échantillon considéré est stationnaire et est foretement mélangeant :

$$\alpha(k) = \sup |P(A \cup B) - P(A)P(B)| \rightarrow 0 \quad \text{quand} \quad k \rightarrow \infty.$$

On se donne un échantillon  $X_1, \dots, X_n, \dots$  et une statistique d'intérêt  $T_n$ . Soit  $Y_i$  le sous-échantillon  $(X_i, X_{i+1}, \dots, X_{i+b_n-1})$  pour  $i \in [1; q]$  et  $q = n - b_n + 1$ . Soit  $T_{b_n, i}$  la statistique obtenue à partir de l'échantillon  $Y_i$  avec le taux d'échantillonnage  $b_n$ . On définit :

$$K_{b_n}(x|X^n, \tau) = \frac{1}{q} \sum_{i=1}^q 1_{\{\tau_n T_{b_n, i} \leq x\}}.$$

**Théorème 2.** On suppose que :  $\|K_{b_n}(\cdot|X^n, \tau) - K(\cdot|P)\|_\infty = o_P(1)$ .

Si  $K$  est continue et atteint ses bornes sur un compact, sur lequel elle est strictement croissante, alors, lorsque  $n$  tend vers l'infini :

$$\tau_{b_n} K_{b_n}^{-1}(t|X^n) = K^{-1}(x, P) + o_P(1)$$

On se place dans les hypothèse

$$\lim_{n \rightarrow +\infty} b_n = +\infty \quad \text{et} \quad \lim_{n \rightarrow +\infty} \frac{b_n}{n} = 0.$$

Supposons que  $\tau_n = n^{-\gamma}$ . En passant au log dans la conclusion du théorème précédent, on obtient :

$$\log |K_{b_n}^{-1}(x|X^n, \tau)| = \log |K^{-1}(x, P)| + \gamma \log b_n + o_P(1).$$

En faisant alors varier les taux de sous-échantillonnage  $b_{n, i}$ , on peut alors estimer  $\gamma$  par moindres carrés ordinaires :

$$\hat{\gamma} = \frac{\sum_{i=1}^I (y_i - \bar{y})(\log b_{i, n} - \overline{\log})}{\sum_{i=1}^I (\log b_{i, n} - \overline{\log})^2},$$

où  $y_i = \log |K_{b_{n, i}}^{-1}(t|X^n)|$ .

Une deuxième méthode est inspirée par la remarque suivante : il suffit d'observer des différences de quantiles. En effet, si l'on prend l'équation du théorème 2 pour deux quantiles d'ordre  $0 < t_1 < t_2$ , et que l'on soustrait l'une à l'autre, après avoir passé au log, on obtient :

$$\log |K_{b_n}^{-1}(t_1|X^n) - K_{b_n}^{-1}(t_2|X^n)| = \log |K^{-1}(t_1|P) - K^{-1}(t_2|P)| + \gamma \log b_n + o_P(1).$$

Avec plusieurs quantiles d'ordre  $0 < t_1 < \dots < t_J < 1$ , on obtient un système :

$$y_{ij} = \log |K_{b_{n, i}}^{-1}(t_j|X^n)| = a_j + \gamma \log b_{n, i} + u_{ij},$$

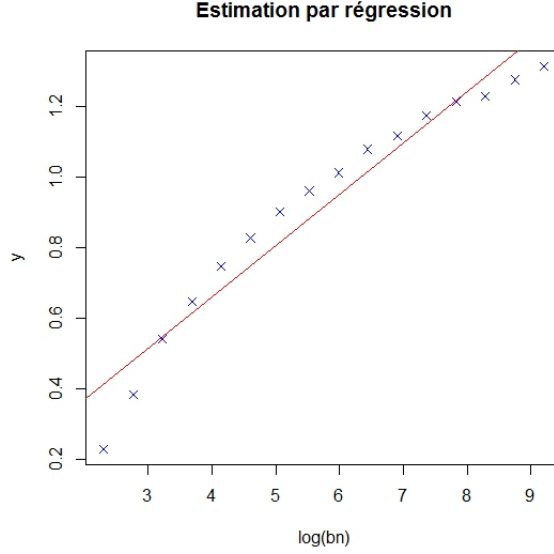


FIGURE 2 – Régression des log-quantiles obtenus par bootstrap sur  $\log b_n$  dans le cas de la loi normale. Ici  $I = 16$  et  $N = 10^5$ , on obtient  $\gamma_I = 0.1494989$ .

où  $a_j = \log |K^{-1}(t_j|P)|$  et  $u_{ij} = o_P(1)$ .

Un estimateur de type ANOVA est

$$\gamma_{IJ} = \frac{\sum_{i=1}^I (y_{i..} - \bar{y})(\log b_{i,n} - \overline{\log})}{\sum_{i=1}^I (\log b_{i,n} - \overline{\log})^2},$$

**Théorème 3.** Soit  $X$  une suite stationnaire et fortement mélangeante, dont la statistique d'intérêt  $\tau_n T_n$  possède une distribution asymptotique, lorsque  $\tau_n = n^{-\gamma}$ ,  $\gamma > 0$  inconnu. On suppose de plus que  $K$  est strictement croissante sur un intervalle borné et continue. On choisit des point  $t_j$  dans  $(0, 1)$  et différents taux de sous-échantillonnage  $n^{\beta_i}$ ,  $1 > \beta_1 > \dots > \beta_I > 0$ . Alors :

$$\gamma_{IJ} = \gamma + o_P((\log n)^{-1})$$

Voici des estimateurs de  $\gamma$  obtenus par la méthode donnée par le théorème 3. Ici  $I = 16$  et  $J = 10$ , les échantillons sont de taille  $N = 100000$ , et l'on a pris  $\beta_i = 10^i$  pour  $i$  allant de 1 à 4.

<b>Lois</b>	<b>Normale</b>	<b>Pareto</b>	<b>Uniforme</b>
$\gamma_{IJ}$	0.003967868	0.003950971	0.004037952

FIGURE 3 – Simulations.

## Références

- [1] Dimitris N. Politis Patrice Bertail, Christian Haefke. A subsampling approach to estimating the distribution of diverging statistics with applications to assessing financial market risks. 2001.
- [2] Joseph P. Romano Patrice Bertail, Dimitris N. Politis. On subsampling estimators with unknown rate of convergence. 1995.